



VerifyAI

Análisis de Autenticidad

Nicole Dávila

Julia Castillo

Rodrigo Sosa

Gabriel Muñoz

Nelson Osdani


| La Epidemia de Datos Falsos

El Desafío de la Desinformación

Las plataformas digitales modernas facilitan la rápida dispersión de narrativas falsas. Los seres humanos carecen del tiempo de análisis necesario para auditar cada dato en tiempo real, amplificando el riesgo social.

Alta velocidad de impacto: Los contenidos falsos logran un alcance masivo de difusión más veloz que las aclaraciones oficiales.

Complejidad lingüística: Los creadores de desinformación utilizan sesgos emocionales y terminología deliberadamente confusa.



| La Solución Propuesta

Motor Inteligente Supervisado

Entrenado sobre corpus masivos estructurados, VerifyAI realiza una clasificación binaria precisa mediante la vectorización matemática del texto, determinando el nivel de confianza del veredicto.

Optimizado con algoritmos de Regresión Logística para entregar veredictos rápidos y reproducibles.

Auditoría Lingüística Local


El sistema analiza polaridad del sentimiento, niveles de subjetividad y complejidad léxica, operando al 100% en infraestructura interna protegida.

También utiliza APIs externas para verificar la veracidad de los artículos sugeridos al usuario.

Pipeline de Inferencia



Desempeño del Clasificador



El entrenamiento se ejecuta mediante los scripts `train_isot.py` y `train_liar.py`. El análisis revela una precisión excepcional (>99%) al auditar textos completos estructurados (ISOT). No obstante, decae al 62.8% frente a frases de corte político cortas (LIAR), validando que el tamaño del corpus textual influye significativamente en los modelos estadísticos tradicionales.

Modelo de ML & Features

$$P(y = 1 | x) = \frac{1}{1 + e^{-(w^T x + b)}}$$

El vector de pesos (w) se construye a partir de un vocabulario optimizado de 50,000 rasgos clave de n -gramas.

Algoritmo: Regresión logística (clasificación binaria: FALSE / REAL)

Extracción de características: TF-IDF (Term Frequency–Inverse Document Frequency)

Convierte el texto del artículo en vectores ponderados de importancia de las palabras.

Reduce la importancia de las palabras comunes ("the", "said") y aumenta la de los términos distintivos.

Configurado con: max_features, rango de n -gramas, eliminación de palabras vacías, conversión a minúsculas.

¿Por qué la regresión logística?

- **Interpretable:** los coeficientes de las características se corresponden directamente con la importancia de las palabras.
- Inferencia rápida, base sólida para textos dispersos de alta dimensionalidad.
- Impulsa las "palabras más influyentes" que se muestran en el panel de control.

| Limitaciones

En sí, lo que hace el modelo de VerifyAI es:

- Evalúa el estilo lingüístico y los patrones de palabras, no la precisión factual.
- TF-IDF carece de comprensión semántica/contextual (no reconoce el sarcasmo, la negación ni los sinónimos).

Algunos riesgos conocidos:

- Puede aprender parcialmente el estilo de la fuente (p. ej., la redacción de Reuters) en lugar de la veracidad pura.
- Generalización limitada a nuevos temas/estilos de escritura fuera de los datos de entrenamiento.
- Soporte únicamente en inglés


¿Qué es el ML frente al enriquecimiento?:

- Modelo de ML → veredicto, confianza, palabras clave.
- Lógica independiente → sentimiento, nivel de lectura, artículos relacionados (NewsAPI), citas.


¿Por qué no usar transformadores (BERT, etc.)?

- Requisitos de interpretabilidad, alcance/tiempo del proyecto, tamaño del dataset adecuado para el ML clásico.

Arquitectura



Arquitectura de Red



| Ciberseguridad e Integridad de Datos



Hashing de Credenciales

Protección estricta de usuarios y contraseñas mediante el algoritmo criptográfico robusto bcrypt en el archivo de base de datos.



Estrategia Stateless JWT

Uso de firmas JWT firmadas bajo algoritmo simétrico HS256 para resguardar la identidad de los usuarios que consumen la API.



Seguridad Relacional

Restricción de consultas parametrizadas en PostgreSQL, previniendo inyecciones SQL y vinculando el historial únicamente a usuarios autenticados.

| ConectaTEC



Entrar desde la red del Tec o Nube



Entrar desde internet

| Mejoras y Evolución Tecnológica

- 1. Inferencia Multimodal Avanzada: Expansión de la IA de clasificación para detectar alteraciones y manipulación sintética de audio (deepfakes de voz) y video.
- 2. IA Explicable : Integración visual en el frontend en React para resaltar de manera dinámica qué oraciones, términos exactos o sesgos gramaticales levantaron las alarmas del clasificador.
- 3. Integración en Tiempo Real: Desarrollo de extensiones de navegador que analicen de forma activa el feed de noticias mientras el analista o periodista navega en la web.
- 4. Soporte multi-lenguaje: Habilitar el análisis de artículos y/o noticias diferentes al inglés